

АННОТАЦИЯ

В данной работе анализируются фазовые траектории сигналов ЭЭГ и фМРТ, спроецированные в латентное пространство, которое порождается контрастивно обученной моделью совместного представления этих двух модальностей. Ключевая цель исследования - изучить взаимосвязь между временными рядами фМРТ и ЭЭГ. Для её достижения были определены следующие шаги: формализовать аддитивную порождающую модель данных; обучить модель, способную отображать обе модальности в единое скрытое пространство; использовать статистические критерии для подтверждения работы модели; применить ССА и ССМ для исследования взаимосвязи фазовых траекторий ЭЭГ и фМРТ, получаемых с помощью полученной модели.

В итоге разработана модель, построенная на адаптации предварительно обученных энкодеров и реализующая предложенную аддитивную модель данных. С использованием методов ССА и ССМ зафиксирована значимая взаимная корреляция, что подтверждает кодирование общего стимула как в ЭЭГ, так и в фМРТ. Рекомендуется формировать положительные пары из данных разных испытуемых для обеспечения инвариантности к субъекту, а также использовать обучаемые сдвиги для субъектов с регуляризацией, для избежания неявного запоминания индивидуальных особенностей испытуемого при минимизации функции потерь, что позволяет предотвратить переобучение и ухудшение результатов на тестовой выборке.

СОДЕРЖАНИЕ

АННОТАЦИЯ	2
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	5
ВВЕДЕНИЕ	8
1 АНАЛИТИЧЕСКИЙ ОБЗОР И ПОСТАНОВКА ЗАДАЧИ	12
1.1 Физиология одновременной регистрации ЭЭГ и фМРТ	12
1.1.1 Нейроваскулярное сопряжение и гемодинамический отклик	12
1.1.2 Набор данных NatView	13
1.2 Контрастивное обучение: теоретические основы	14
1.2.1 Информационная интерпретация InfoNCE	14
1.2.2 Анализ выравнивания и равномерности	15
1.2.3 Предотвращение коллапса: VICReg	16
1.3 Методы кодирования нейрофизиологических сигналов	17
1.3.1 Развитие глубокого обучения для ЭЭГ	17
1.3.2 Mamba и модели пространства состояний для фМРТ	17
1.3.3 Низкоранговая адаптация LoRA	18
1.3.4 Модель совместного ответа SRM	19
2 ПОСТАНОВКА ЗАДАЧИ	20
2.1 Данные, отображения и латентное пространство	20
2.2 Порождающая модель представлений	21
2.3 Отношение сопоставления и очищенные представления	22
2.4 Скоринг как апостериорная вероятность сопоставления	24
2.5 Оценка сдвига испытываемого	26
3 МЕТОДЫ.....	29
3.1 Общая схема	29
3.2 Энкодер ЭЭГ	30
3.3 Энкодер фМРТ	30
3.4 Предобработка ЭЭГ и фМРТ	31
3.5 Формирование батча	32

3.6	Субъектные смещения	33
3.7	Анализ латентного пространства: ССА и ССМ	34
3.8	Функция потерь	35
4	ВЫЧИСЛИТЕЛЬНЫЙ ЭКСПЕРИМЕНТ	36
4.1	Метрики оценки	36
4.2	Статистический анализ	36
4.2.1	ССА и ССМ	39
4.3	Метрики качества выравнивания	40
4.3.1	Данные	40
4.4	Ограничения метода и практическая значимость	42
4.4.1	Ограничения текущего подхода	42
4.4.2	Практическая значимость	42
4.4.3	Направления дальнейших исследований	43
	ЗАКЛЮЧЕНИЕ	44
	СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	45

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

ЭЭГ электроэнцефалография

фМРТ функциональная магнитно-резонансная томография

BOLD blood-oxygen-level dependent — сигнал, зависящий от уровня кислорода в крови

HRF haemodynamic response function — гемодинамическая функция отклика

TR repetition time — период повторения фМРТ-объёма

ИНМ интерфейс мозг-компьютер (brain-computer interface, BCI)

LoRA Low-Rank Adaptation — метод низкоранговой адаптации

MRR Mean Reciprocal Rank — средний обратный ранг

CCA canonical correlation analysis — канонический корреляционный анализ

CCM convergent cross mapping — сходящееся перекрёстное отображение

InfoNCE information noise-contrastive estimation

SSM state space model — модель пространства состояний

ViT vision transformer — трансформер для изображений

CLIP Contrastive Language-Image Pre-training

MLP multilayer perceptron — многослойный перцептрон

BN batch normalization — батч-нормализация

GELU Gaussian Error Linear Unit

PCA principal component analysis — метод главных компонент

ROI region of interest — область интереса

$\mathbb{R}$ множество вещественных чисел

$\mathbb{S}^d$ единичная сфера в $\mathbb{R}^d$

$\text{vMF}(\mu, \kappa)$ распределение фон Мизеса-Фишера на $\mathbb{S}^d$

$\text{prm}(\cdot)$ нормировка на единичную сферу: $y/\|y\|$

S число испытуемых

T число моментов стимула

d размерность общего латентного пространства

B размер батча

τ температурный параметр InfoNCE

$\mathbf{E}_{s,t}$ наблюдение ЭЭГ испытуемого s в момент t

$\mathbf{F}_{s,t}$ наблюдение фМРТ испытуемого s в момент t

$\mathcal{E}_e, \mathcal{E}_f$ энкодеры ЭЭГ и фМРТ

$\mathcal{P}_e, \mathcal{P}_f$ проекторы ЭЭГ и фМРТ на $\mathbb{S}^d$

$\tilde{\mathbf{f}}, \tilde{\mathbf{g}}$ очищенные отображения ЭЭГ и фМРТ

$h_{s,t}^e, h_{s,t}^f$ предпроекционные представления ЭЭГ и фМРТ

c_t латентный код стимула в момент t

u_s^m субъектный сдвиг испытуемого s , модальность m

$\mathbf{b}_s^m$ обучаемая оценка субъектного смещения

Γ_s^e, Γ_s^f фазовые траектории ЭЭГ и фМРТ в латентном пространстве

$I(X; Y)$ взаимная информация между представлениями модальностей

ВВЕДЕНИЕ

Актуальность темы исследования. Нейронная активность мозга развивается одновременно на множестве пространственных и временных масштабов. Электроэнцефалография (ЭЭГ) и функциональная магнитно-резонансная томография (фМРТ) фиксируют эту активность через принципиально разные физиологические прокси, обладая взаимодополняющими свойствами:

- **ЭЭГ** напрямую регистрирует суммарные постсинаптические потенциалы с миллисекундным временным разрешением (~ 1 мс). Метод мобилен, дешев и применим в клинике, но страдает от крайне низкого пространственного разрешения из-за эффекта затухания и суперпозиции сигналов в тканях головы (проблема обратной задачи).
- **фМРТ** измеряет гемодинамический BOLD-контраст, обеспечивая высокую пространственную локализацию (~ 2 мм). Однако метод ограничен низким временным разрешением (порядка секунд) и требует полной неподвижности пациента внутри томографа.

Синхронная запись ЭЭГ и фМРТ позволяет объединить сильные стороны обоих подходов в рамках одного эксперимента. Несмотря на техническую сложность — необходимость фильтрации мощных градиентных и баллистокордиографических (BCG) артефактов томографа, — современные немагнитные системы позволяют стабильно регистрировать высокоплотную ЭЭГ (до 64 каналов) непосредственно во время сканирования.

Центральная задача данного исследования — научиться выравнивать внутренние представления ЭЭГ и фМРТ в едином латентном пространстве и изу-

чить их взаимосвязь. Успешное построение такого общего пространства кардинально меняет возможности нейровизуализации, открывая три ключевых направления:

- 1) **Виртуальная фМРТ-томография (Портативный прокси):** ЭЭГ сможет выступать в качестве дешевого, мобильного и доступного аналога фМРТ. Это позволит проводить высокоточный мониторинг когнитивных и клинических состояний вне стен томографа — в естественной для человека среде.
- 2) **Кросс-модальная дистилляция знаний:** Появится возможность переносить богатую пространственную разметку фМРТ в ЭЭГ-модели. Дистилляция представлений (knowledge distillation) позволит обучать сверхточные ЭЭГ-декодеры на скрытых признаках фМРТ, которые невозможно извлечь из одной лишь ЭЭГ-информации.
- 3) **Сквозной кросс-модальный поиск и генерация:** Общее латентное пространство делает возможной прямую трансляцию модальностей. Зная лишь ЭЭГ-сигнал, мы сможем восстанавливать, искать и реконструировать соответствующий ему трехмерный фМРТ-отклик, фактически предсказывая пространственную динамику глубоких структур мозга по поверхностным электрическим потенциалам.

Анализ состояния проблемы.

Методы обучения совмещающие данные разной природы в последние годы добились впечатляющих результатов за пределами изучения мозга. Например, модель CLIP [1], обученная на 400 миллионах пар текст изображение, спо-

собна обобщаться на объекты из категорий которых не было в обучающей выборке, с точностью, сопоставимой с fully-supervised моделями. В области нейродекодирования MindEye [2] использует функцию потерь InfoNCE для сопоставления фМРТ-откликов мозга с CLIP-пространством изображений и реконструирует просматриваемые образы методами диффузии. NeuroBOLT [3] делает шаг в направлении ЭЭГ-фМРТ: метод предлагает синтез фМРТ-представлений из resting-state ЭЭГ на основе предобученного LaBraM-энкодера.

Принципиальное ограничение этих методов — допущение о сильной содержательной связи между модальностями. В задаче выравнивания ЭЭГ–фМРТ это допущение неоправданно по нескольким причинам: Во-первых, гемодинамической функции отклика (HRF) варьируется между испытуемыми и между областями мозга [4]. Во-вторых, ЭЭГ регистрирует преимущественно активность коры головного мозга, тогда как фМРТ охватывает весь объём мозга. В-третьих, индивидуальные анатомические различия приводят к выраженной межсубъектной вариативности ЭЭГ-сигналов, которую надо учитывать.

Открытым остаётся вопрос о природе сигнала, связывающего ЭЭГ и фМРТ: является ли он кросс-субъектным или внутрисубъектным, и какую геометрию образуют совместные представления модальностей в латентном пространстве. Настоящая работа исследует эти вопросы через призму изучения фазовых траекторий ЭЭГ и фМРТ в пространстве полученном контрастивно обученными энкодерами модальностей, функция потерь при этом продиктована аддитивной порождающей моделью данных.

Цель работы — Исследовать взаимосвязь фазовых траекторий в латент-

ном пространстве порожденном контрастивно обученными энкодерами обеих модальностей на единичной сфере

Задачи исследования:

- 1) Реализовать двухмодальную архитектуру выравнивания на основе энкодеров LaBraM [5] и NeuroSTORM, адаптированных методом LoRA [6].
- 2) Предложить и обосновать механизм субъект-зависимых смещений для решения проблемы обобщаемости модели.
- 3) Применить методы ССА и ССМ в латентном пространстве полученной обученной моделью.
- 4) Определить ограничения метода и направления дальнейших исследований.

Методы исследования: порождающая вероятностная модель с латентным кодом стимула; многопозитивная InfoNCE как апостериорная вероятность сопоставления при гауссовских предположениях [7]; LoRA [6]; LP-FT [8]; статистические критерии анализ фазовых траекторий в латентном пространстве с помощью ССА и ССМ.

Практическая значимость. Предложенная порождающая формализация даёт теоретическое обоснование выбору функции потерь и механизму субъектного сдвига, переносимым на другие задачи мультисубъектного нейродекодирования. Анализ фазовых траекторий может служить инструментом интерпретации латентных пространств в задачах нейровизуализации.

Апробация. Исследование полностью выполнено на открытом наборе данных NatView [9]; все эксперименты воспроизводимы.

1 АНАЛИТИЧЕСКИЙ ОБЗОР И ПОСТАНОВКА ЗАДАЧИ

1.1 Физиология одновременной регистрации ЭЭГ и фМРТ

1.1.1 Нейроваскулярное сопряжение и гемодинамический отклик

Связь между нейронной активностью и сигналом фМРТ опосредована механизмом нейроваскулярного сопряжения. Возбуждение нейронов запускает выделение вазоактивных медиаторов, расширяющих артериолы. Локальный приток крови избыточен по сравнению с потреблением кислорода, что снижает концентрацию парамагнитного дезоксигемоглобина и увеличивает долю диамагнитного оксигемоглобина. Данный сдвиг фиксируется как скачок BOLD-сигнала [4].

Основным инструментом временного связывания мультимодальных данных (в частности, ЭЭГ и фМРТ) является гемодинамическая функция отклика (HRF). Математически каноническая HRF моделируется линейной комбинацией двух гамма-распределений [10]:

$$h(t) = \frac{t^{a_1-1} e^{-t/b_1}}{b_1^{a_1} \Gamma(a_1)} - c \frac{t^{a_2-1} e^{-t/b_2}}{b_2^{a_2} \Gamma(a_2)}, \quad (1.1)$$

где первое слагаемое описывает фазу нарастания и пика (максимальный приток оксигемоглобина), а второе — последующее падение сигнала ниже базовой линии (undershoot).

Использование фиксированной HRF при совместном анализе ЭЭГ и фМРТ ограничено двумя ключевыми факторами. Во-первых, существенная гемодина-

мическая задержка приводит к тому, что BOLD-сигнал значительно запаздывает относительно электрической активности, и регистрируемый фМРТ-объем отражает нейронные события, произошедшие на несколько секунд раньше. Во-вторых, пространственно-временная вариативность формы, амплитуды и латентности HRF делает ее индивидуальной для каждого субъекта и изменчивой даже между различными областями коры в пределах одного мозга [11].

Высокая вариативность HRF делает простой фиксированный временной сдвиг неэффективным при формировании обучающих пар.

1.1.2 Набор данных NatView

NatView (Naturalistic Viewing EEG-fMRI Dataset) [9] — открытый набор данных одновременной ЭЭГ-фМРТ от Nathan Kline Institute. Датасет содержит 272 одновременных записи от 22 испытуемых (11 мужчин, 11 женщин; возраст 23-51 лет; все здоровые взрослые без нейропсихиатрических диагнозов).

Протокол просмотра включает семь натуралистических стимулов: анимационный фильм *Despicable Me* (хаотичный нарратив), документальный фильм *Monkey clips*, короткометражки *The Present*, *Inscapes* и ряд других. Суммарное время просмотра на испытуемого составляет от 43 до 78 минут. Натуралистические стимулы обеспечивают широкий охват когнитивных состояний: зрительное восприятие, слуховая обработка, эмоциональный отклик, нарративная обработка [12].

Параметры записи:

- ЭЭГ: 64-канальная система Brain Products с электродами по 10-20, частота дискретизации 5000 Гц, снижена до 200 Гц после фильтрации.

- фМРТ: 3 Тл Siemens MAGNETOM, EPI T2*-взвешенная последовательность, TR = 2,1 с, TE = 30 мс, угол поворота 75°, воксель $2 \times 2 \times 2$ мм, матрица $96 \times 96 \times 72$ (обрезается до 96^3).
- Структурный МРТ: T1-взвешенный MPRAGE, 1 мм изотропный воксель.

1.2 Контрастивное обучение: теоретические основы

1.2.1 Информационная интерпретация InfoNCE

Функция потерь InfoNCE [7] напрямую связана с максимизацией нижней границы взаимной информации между представлениями различных модальностей.

Пусть X и Y — случайные векторы из двух модальностей с совместным распределением $p(X, Y)$ и маргинальными распределениями $p(X)$, $p(Y)$. Взаимная информация определяется следующим образом:

$$I(X; Y) = \mathbb{E}_{p(X, Y)} \left[\log \frac{p(X, Y)}{p(X)p(Y)} \right]. \quad (1.2)$$

На практике для выборки (батча) размера B , состоящей из одной позитивной пары $(x_i, y_i) \sim p(X, Y)$ и $B - 1$ негативных примеров $y_j \sim p(Y)$, функция потерь InfoNCE записывается как:

$$\mathcal{L}_{\text{InfoNCE}} = -\mathbb{E}_{p(X, Y)} \left[\log \frac{\exp(\text{sim}(x_i, y_i)/\tau)}{\exp(\text{sim}(x_i, y_i)/\tau) + \sum_{j=1}^{B-1} \exp(\text{sim}(x_i, y_j)/\tau)} \right], \quad (1.3)$$

где $\text{sim}(x, y)$ — функция сходства (обычно косинусное расстояние), а τ — температурный параметр.

Как доказано в работе [7], минимизация $\mathcal{L}_{\text{InfoNCE}}$ эквивалентна максимизации нижней оценки взаимной информации:

$$I(X; Y) \geq \log B - \mathcal{L}_{\text{InfoNCE}}. \quad (1.4)$$

Из неравенства (1.4) следует фундаментальное ограничение метода: при идеальной сходимости ($\mathcal{L}_{\text{InfoNCE}} \rightarrow 0$) оценка взаимной информации сверху ограничена значением $\log B$. Это означает, что при малом размере батча B данная функция потерь математически неспособна оценить высокую взаимную информацию между модальностями, даже если истинное значение $I(X; Y)$ существенно выше.

1.2.2 Анализ выравнивания и равномерности

Wang и Isola [13] предложили разложение InfoNCE функции потерь на два независимых свойства.

Выравнивание (alignment):

$$\mathcal{L}_{\text{align}} = \mathbb{E}_{(x,y) \sim p_{\text{pos}}} [\|f(x) - g(y)\|^2], \quad (1.5)$$

где p_{pos} — распределение позитивных пар. Оптимальное выравнивание соответствует $f(x) = g(y)$ для совпадающих пар, т.е. косинусному сходству ~ 1 .

Равномерность (uniformity):

$$\mathcal{L}_{\text{unif}} = \log \mathbb{E}_{x,x' \sim p_{\text{data}}} [e^{-2\|f(x) - f(x')\|^2}], \quad (1.6)$$

характеризующая равномерность распределения представлений на единичной

сфере.

Эти две метрики напрямую применимы для контроля обучения модели: рост $\mathcal{L}_{\text{align}}$ без снижения $\mathcal{L}_{\text{unif}}$ свидетельствует о коллапсе латентного пространства. В данной работе их аналогами служат косинусное сходство позитивных пар и эффективный ранг матрицы представлений.

1.2.3 Предотвращение коллапса: VICReg

Коллапс латентного пространства [14] — ситуация, при которой модель проецирует все входы на малое подпространство, что существенно ограничивает вариативность представлений. InfoNCE не предотвращает коллапс явно: теоретически оптимум достигается при равномерном распределении по всей сфере, но численные нестабильности и локальные минимумы могут привести к вырожденным решениям.

VICReg [15] вводит явные регуляризаторы:

$$\mathcal{L}_{\text{VIC}} = \lambda \mathcal{L}_{\text{inv}} + \mu \mathcal{L}_{\text{var}} + \nu \mathcal{L}_{\text{cov}}, \quad (1.7)$$

где $\mathcal{L}_{\text{inv}}$ — инвариантность (расстояние позитивных пар), $\mathcal{L}_{\text{var}}$ — штраф за малую дисперсию вдоль каждого измерения, $\mathcal{L}_{\text{cov}}$ — штраф за ненулевую ковариацию между измерениями. В данной работе VICReg не использовался как основная функция потерь, однако его идея была применена в ходе отладки: эффективный ранг erank служит диагностическим маркером коллапса.

1.3 Методы кодирования нейрофизиологических сигналов

1.3.1 Развитие глубокого обучения для ЭЭГ

Эволюция методов обработки ЭЭГ прошла несколько этапов. Первый — ручной feature engineering: выделение спектров на физиологически важных диапазонах частот (дельта, тета, альфа, бета, гамма), статистик временного ряда и характеристик связности. Второй — компактные свёрточные сети. EEGNet [16] предложил depthwise и pointwise свертки, вдохновленные мобильными архитектурами в компьютерном зрении: первый слой выполняет временную фильтрацию, второй — пространственное объединение каналов. Модель насчитывает лишь несколько тысяч параметров и применима к разнородным парадигмам без переобучения.

Третий этап — большие предобученные трансформеры. LaBraM [5] (Large Brain Model) применяет архитектуру Vision Transformer к ЭЭГ-сигналам: временной ряд каждого канала разбивается на патчи длиной 200, каждый патч проецируется линейным слоем в пространство токенов размерности 200. Предобучение методом векторно-квантованного предсказания нейронного спектра выполнялось на 2500 ч ЭЭГ из 20 наборов данных — это крупнейший в своём классе датасет на момент публикации. Результирующий CLS-токен $\mathbf{h}_e \in \mathbb{R}^{200}$ кодирует глобальное состояние мозга в 200-мерном пространстве.

1.3.2 Mamba и модели пространства состояний для фМРТ

Обработка фМРТ как временного ряда объёмных данных сопряжена с вычислительными трудностями: один объём 96^3 содержит $\approx 884\,736$ вокселей.

Трансформеры масштабируются как $O(n^2)$ по числу токенов, что делает прямое применение ViT нецелесообразным для длинных фМРТ-последовательностей.

Модели Mamba [17] — избирательные пространства состояний (Selective State Space Models, S4/S6) — обеспечивают линейное по n масштабирование при сохранении ёмкости памяти о длинных зависимостях. Рекуррентное обновление скрытого состояния:

$$\mathbf{h}_t = \bar{A} \mathbf{h}_{t-1} + \bar{B} x_t, \quad y_t = C \mathbf{h}_t, \quad (1.8)$$

где $\bar{A}$, $\bar{B}$, C — дискретизованные параметры, а матрица A избирательно сжимает историю через обучаемые временные константы. Режим параллельного обучения на основе сканирующей свёртки обеспечивает практическую эффективность при обучении [17].

NeuroSTORM — гибридный SSM+MLP энкодер, предобученный на 3500 фМРТ-томограммах методом реконструкции маскированных вокселей. Финальное скрытое состояние $\mathbf{H} \in \mathbb{R}^{V \times 288}$ (где V — число вокселей) пространственно усредняется до $\mathbf{h}_f \in \mathbb{R}^{288}$.

1.3.3 Низкоранговая адаптация LoRA

LoRA [6] предложен как метод параметрически эффективной адаптации больших предобученных моделей. Идея: матрица весов $W_0 \in \mathbb{R}^{m \times n}$ заморожена; к ней прибавляется низкоранговое произведение $\Delta W = BA$, где $B \in \mathbb{R}^{m \times r}$, $A \in \mathbb{R}^{r \times n}$, ранг $r \ll \min(m, n)$:

$$W = W_0 + BA, \quad \text{rank}(BA) \leq r. \quad (1.9)$$

Матрица A инициализируется случайно (нормальное распределение), B — нулями (нулевая инициализация гарантирует, что при старте обучения $\Delta W = 0$).

1.3.4 Модель совместного ответа SRM

Chen et al. [18] предложили *модель совместного ответа* (SRM): линейное отображение $W_i \in \mathbb{R}^{V \times k}$ для каждого испытуемого i , проецирующее его фМРТ-данные в общее k -мерное пространство, разделяемое всеми испытуемыми. SRM минимизирует ортогональную задачу Прокруста:

$$\min_{\{W_i\}, S} \sum_{i=1}^{N_s} \|X_i - W_i S\|_F^2, \quad W_i^\top W_i = I_k, \quad (1.10)$$

где $X_i \in \mathbb{R}^{V \times T}$ — данные испытуемого i , $S \in \mathbb{R}^{k \times T}$ — матрица общего ответа. SRM применим, когда межсубъектная согласованность достаточна. При её отсутствии задача (1.10) сводится к шумовой подгонке.

2 ПОСТАНОВКА ЗАДАЧИ

2.1 Данные, отображения и латентное пространство

Определение 1 (Выборка). Пусть $S \in \mathbb{N}$ — число испытуемых, индексируемых $s \in \{1, \dots, S\}$, и $T \in \mathbb{N}$ — число моментов стимула, индексируемых $t \in \{1, \dots, T\}$; при фиксированном t всем испытуемым предъявляется один и тот же стимул. Наблюдения индексируются множеством $\mathcal{I} \subseteq \{1, \dots, S\} \times \{1, \dots, T\}$ синхронных пар

$$\mathbf{E}_{s,t} \in \mathbb{R}^{C \times T_e}, \quad \mathbf{F}_{s,t} \in \mathbb{R}^{X \times Y \times Z \times T_f}, \quad (s, t) \in \mathcal{I},$$

где C, T_e — число каналов и временных отсчётов ЭЭГ, X, Y, Z, T_f — пространственно-временные размерности фМРТ.

Определение 2 (Отображения и латентное пространство). Положим $\mathbb{S}^d := \{x \in \mathbb{R}^d : \|x\|_2 = 1\}$ — единичная сфера в $\mathbb{R}^d$, и $\text{norm}(y) := y/\|y\|$ — нормировка на $\mathbb{S}^d$. Энкодеры

$$\mathcal{E}_e : \mathbb{R}^{C \times T_e} \rightarrow \mathbb{R}^{d_e}, \quad \mathcal{E}_f : \mathbb{R}^{X \times Y \times Z \times T_f} \rightarrow \mathbb{R}^{d_f},$$

проекторы $\mathcal{P}_e : \mathbb{R}^{d_e} \rightarrow \mathbb{S}^d$, $\mathcal{P}_f : \mathbb{R}^{d_f} \rightarrow \mathbb{S}^d$ вида $\mathcal{P}_e(x) = \text{norm}(W_e x)$, $\mathcal{P}_f(x) = \text{norm}(W_f x)$ с линейными отображениями $W_e : \mathbb{R}^{d_e} \rightarrow \mathbb{R}^d$, $W_f : \mathbb{R}^{d_f} \rightarrow \mathbb{R}^d$.

Искомые отображения суть $\mathbf{f} = \mathcal{P}_e \circ \mathcal{E}_e$ и $\mathbf{g} = \mathcal{P}_f \circ \mathcal{E}_f$. Обозначим через

$$h_{s,t}^e := W_e \mathcal{E}_e(\mathbf{E}_{s,t}) \in \mathbb{R}^d, \quad h_{s,t}^f := W_f \mathcal{E}_f(\mathbf{F}_{s,t}) \in \mathbb{R}^d$$

представления обеих модальностей в общем предпроекционном пространстве $\mathbb{R}^d$ (на входе нормировки).

Определение 3 (Распределение фон Мизеса-Фишера). Случайный вектор $z \in \mathbb{S}^d$ имеет распределение фон Мизеса-Фишера $\text{vMF}(\mu, \kappa)$ с направлением $\mu \in \mathbb{S}^d$ и концентрацией $\kappa \geq 0$, если его плотность относительно равномерной меры на $\mathbb{S}^d$ равна

$$p(z; \mu, \kappa) = C_d(\kappa) \exp(\kappa \langle \mu, z \rangle), \quad C_d(\kappa) = \frac{\kappa^{d/2-1}}{(2\pi)^{d/2} I_{d/2-1}(\kappa)},$$

где I_ν — модифицированная функция Бесселя первого рода порядка ν . При $\kappa = 0$ распределение вырождается в равномерное на $\mathbb{S}^d$.

2.2 Порождающая модель представлений

Предположение 4 (Латентная модель представлений). Существуют независимые латентные переменные

$$c_t \sim \mathcal{N}(0, \tau_c^2 I_d), \quad u_s^m \sim \mathcal{N}(0, \sigma_u^2 I_d), \quad \varepsilon_{s,t}^m \sim \mathcal{N}(0, \sigma_\varepsilon^2 I_d), \quad m \in \{e, f\},$$

независимые по t , по s и по наблюдениям соответственно ($\tau_c, \sigma_u, \sigma_\varepsilon > 0$), такие, что предпроекционные представления из Определения 2 удовлетворяют

$$h_{s,t}^e = c_t + u_s^e + \varepsilon_{s,t}^e, \quad h_{s,t}^f = c_t + u_s^f + \varepsilon_{s,t}^f.$$

Здесь c_t — латентная переменная стимула, общая для обеих модальностей и всех испытуемых момента t ; u_s^m — сдвиг испытуемого, постоянный внутри s ; ε — шум наблюдения.

Из аддитивной структуры и независимости латентных переменных совместная плотность факторизуется как

$$p(\{h_{s,t}^m\}, \{c_t\}, \{u_s^m\}) = \prod_t p(c_t) \prod_{s,m} p(u_s^m) \prod_{(s,t) \in \mathcal{I}, m} p(h_{s,t}^m \mid c_t, u_s^m),$$

$p(h_{s,t}^m \mid c_t, u_s^m) = \mathcal{N}(c_t + u_s^m, \sigma_\varepsilon^2 I_d)$. В частности, при условии на (c_t, u_s^m) наблюдения условно независимы; латентная переменная c_t при этом не факторизуется по s , связывая всех испытуемых момента t .

Утверждение 5 (Наведённая внутрисубъектная зависимость). *В условиях Предположения 4 для любых $t \neq t'$ и любой модальности $m \in \{e, f\}$*

$$\text{Cov}(h_{s,t}^m, h_{s,t'}^m) = \sigma_u^2 I_d \neq 0,$$

то есть представления одного испытуемого в разные моменты статистически зависимы через общий сдвиг u_s^m .

Доказательство. Все переменные центрированы. Используя $c_t \perp c_{t'}$, попарную независимость шумов и независимость $c \perp u \perp \varepsilon$,

$$\text{Cov}(c_t + u_s^m + \varepsilon_{s,t}^m, c_{t'} + u_s^m + \varepsilon_{s,t'}^m) = \text{Cov}(u_s^m, u_s^m) = \sigma_u^2 I_d. \quad \square$$

2.3 Отношение сопоставления и очищенные представления

Определение 6 (Сопоставление и позитивная группа). Наблюдения (s, t) и (s', t') называются *совпадающими* (сопоставленными), если порождены общим стимульным латентом, то есть $t = t'$. Для ЭЭГ-якоря (s, t) позитивная группа есть

множество фМРТ-наблюдений того же момента,

$$P_{(s,t)} := \{(s', t) : s' \in \{1, \dots, S\}, (s', t) \in \mathcal{I}\},$$

и симметрично для фМРТ-якоря.

Определение 7 (Очищенные представления). Пусть $\mathbf{b}_s^m \in \mathbb{R}^d$ — оценка сдвига u_s^m . Очищенные отображения определяются вычитанием оценки до нормировки:

$$\tilde{\mathbf{f}}(\mathbf{E}_{s,t}) = \text{nrm}(h_{s,t}^e - \mathbf{b}_s^e), \quad \tilde{\mathbf{g}}(\mathbf{F}_{s,t}) = \text{nrm}(h_{s,t}^f - \mathbf{b}_s^f).$$

При $\mathbf{b}_s^m = u_s^m$ преднормировочный остаток при условии латентной переменной c_t имеет вид $c_t + \varepsilon \mid c_t \sim \mathcal{N}(c_t, \sigma_\varepsilon^2 I_d)$.

Формальная постановка. Требуется построить отображения $\tilde{\mathbf{f}}, \tilde{\mathbf{g}} : \cdot \rightarrow \mathbb{S}^d$ (т.е. энкодеры $\mathcal{E}_e, \mathcal{E}_f$, проекторы $\mathcal{P}_e, \mathcal{P}_f$ и оценки сдвигов $\{\mathbf{b}_s^m\}$), для которых косинусное сходство

- (i) максимально для совпадающих наблюдений: $\langle \tilde{\mathbf{f}}(\mathbf{E}_{s,t}), \tilde{\mathbf{g}}(\mathbf{F}_{s',t}) \rangle \rightarrow \max$;
- (ii) минимально для несовпадающих: $\langle \tilde{\mathbf{f}}(\mathbf{E}_{s,t}), \tilde{\mathbf{g}}(\mathbf{F}_{s',t'}) \rangle \rightarrow \min$ при $t \neq t'$;
- (iii) инвариантно к сдвигу испытуемого u_s .

Условие (iii) необходимо для (ii): по Утверждению 5 без устранения u_s сходство несовпадающих наблюдений одного испытуемого остаётся положительным величиной порядка σ_u^2 , что противоречит требованию минимизации. Дальнейшие утверждения обосновывают (а) выбор косинусного сходства очищенных представлений в качестве скоринговой функции, (б) вид функции потерь и (в) оценку $\mathbf{b}_s^m$, реализующую (iii).

2.4 Скоринг как апостериорная вероятность сопоставления

Лемма 8. Пусть $a, b \in \mathbb{R}^d$ — преднормировочные очищенные представления пары, $a = c + \varepsilon_a$, $b = c + \varepsilon_b$, $c \sim \mathcal{N}(0, \tau_c^2 I_d)$, $\varepsilon_a, \varepsilon_b \sim \mathcal{N}(0, \sigma_\varepsilon^2 I_d)$ (независимо).

Рассмотрим две гипотезы: H_1 — векторы порождены общим латентом ($a = c + \varepsilon_a$, $b = c + \varepsilon_b$); H_0 — векторы a, b независимы. Тогда

$$\log \Lambda(a, b) := \log \frac{p(a, b \mid H_1)}{p(a, b \mid H_0)} = \alpha \langle a, b \rangle - \beta (\|a\|^2 + \|b\|^2) + \text{const},$$

$$\alpha = \frac{q}{p^2 - q^2}, \quad \beta = \frac{q^2}{2p(p^2 - q^2)}, \quad p := \tau_c^2 + \sigma_\varepsilon^2, \quad q := \tau_c^2.$$

Если, кроме того, $\|a\| = \|b\| = 1$ (то есть $a, b \in \mathbb{S}^d$), второй член постоянен и

$$\log \Lambda(a, b) = \alpha \langle a, b \rangle + \text{const}', \quad \alpha = \frac{\tau_c^2}{\sigma_\varepsilon^2(\sigma_\varepsilon^2 + 2\tau_c^2)} > 0.$$

Доказательство. Обозначим $z := (a, b) \in \mathbb{R}^{2d}$. Поскольку $a, b \in \mathbb{R}^d$ совместно гауссовы (сумма независимых гауссовских латентных переменных), плотности $p(a, b \mid H_1)$, $p(a, b \mid H_0)$ определены на всём $\mathbb{R}^{2d}$ и сравнение корректно без каких-либо ограничений на нормы. При H_1 ковариация $\text{Cov}(a) = \text{Cov}(b) = pI_d$, $\text{Cov}(a, b) = \text{Cov}(c, c) = qI_d$, поскольку единственная общая компонента — латентная переменная c . Значит при H_1 и H_0 соответственно

$$\Sigma_1 = \begin{pmatrix} pI_d & qI_d \\ qI_d & pI_d \end{pmatrix}, \quad \Sigma_0 = pI_{2d}.$$

Блоки Σ_1 кратны I_d и коммутируют, поэтому, рассматривая $M = \begin{pmatrix} p & q \\ q & p \end{pmatrix}$ с соб-

ственными значениями $p \pm q$,

$$|\Sigma_1| = (p^2 - q^2)^d, \quad \Sigma_1^{-1} = \frac{1}{p^2 - q^2} \begin{pmatrix} pI_d & -qI_d \\ -qI_d & pI_d \end{pmatrix}.$$

Тогда $z^\top \Sigma_1^{-1} z = \frac{1}{p^2 - q^2} (p\|a\|^2 - 2q\langle a, b \rangle + p\|b\|^2)$ и $z^\top \Sigma_0^{-1} z = (\|a\|^2 + \|b\|^2)/p$.

Для центрированных гауссиан

$$\log \Lambda = -\frac{1}{2} z^\top \Sigma_1^{-1} z + \frac{1}{2} z^\top \Sigma_0^{-1} z - \frac{1}{2} \log |\Sigma_1| + \frac{1}{2} \log |\Sigma_0|.$$

Группируя по типам членов, получаем первое утверждение с $\alpha = q/(p^2 - q^2)$, $\beta = q^2/[2p(p^2 - q^2)]$ (последние два слагаемых $-\frac{1}{2} \log |\Sigma_1| + \frac{1}{2} \log |\Sigma_0|$ не зависят от a, b и входят в const). Если дополнительно $\|a\| = \|b\| = 1$, член $\beta(\|a\|^2 + \|b\|^2) = 2\beta$ становится числовой константой и поглощается в const' ; подстановка $p = \tau_c^2 + \sigma_\varepsilon^2$, $q = \tau_c^2$ в α даёт указанное значение. $\square$

Следствие 9 (InfoNCE-softmax как апостериорная вероятность). Пусть заданы якорь $\mathbf{F}_j$ и множество кандидатов $\{\mathbf{E}_i\}_{i=1}^B$, среди которых ровно один элемент с неизвестным индексом I образует с $\mathbf{F}_j$ совпадающую пару, а прочие кандидаты независимы от якоря. При равномерном априорном распределении индекса I на множестве $\{1, \dots, B\}$, апостериорная вероятность истинности сопоставления $I = i$ при условии наблюдаемых очищенных представлений равна

$$P(I = i \mid \{\tilde{\mathbf{f}}(\mathbf{E}_k)\}_{k=1}^B, \tilde{\mathbf{g}}(\mathbf{F}_j)) = \frac{\exp(\langle \tilde{\mathbf{f}}(\mathbf{E}_i), \tilde{\mathbf{g}}(\mathbf{F}_j) \rangle / \tau)}{\sum_{k=1}^B \exp(\langle \tilde{\mathbf{f}}(\mathbf{E}_k), \tilde{\mathbf{g}}(\mathbf{F}_j) \rangle / \tau)}, \quad \tau = \alpha^{-1}.$$

Доказательство. Обозначим $\mathcal{H}_i$ гипотезу о том, что истинной парой для $\mathbf{F}_j$ является $\mathbf{E}_i$, а остальные кандидаты независимы. Совместное правдоподобие на-

блюдений при гипотезе $\mathcal{H}_i$ факторизуется как $p(\cdots | \mathcal{H}_i) = [\prod_k p(\tilde{\mathbf{f}}(\mathbf{E}_k))] p(\tilde{\mathbf{g}}(\mathbf{F}_j)) \cdot \Lambda_i$, где $\Lambda_i := \Lambda(\tilde{\mathbf{f}}(\mathbf{E}_i), \tilde{\mathbf{g}}(\mathbf{F}_j))$, а маргинальные множители идентичны для всех i . По формуле Байеса, в силу равномерности априорного распределения, общие множители и аддитивная константа из Леммы 8 сокращаются, что приводит к требуемому выражению при $\tau = \alpha^{-1}$. $\square$

Замечание (Необходимость очистки). Лемма 8 требует, чтобы под H_0 векторы были независимы, а под H_1 их единственной общей компонентой был c . Для сырых представлений $h^m = c + u_s^m + \varepsilon$ это нарушается: по Утверждению 5 окна одного испытуемого коррелированы через u_s , гипотеза H_0 перестаёт быть нулевой, и в значение скоринговой функции входит член $\langle u_{s_i}^e, u_{s_j}^f \rangle$, большой при $s_i = s_j$ независимо от стимула. Скалярное произведение становится достаточной статистикой статистического критерия проверки гипотезы об общем стимуле лишь после вычитания u_s , что обосновывает применение скоринговой функции к очищенным $\tilde{\mathbf{f}}, \tilde{\mathbf{g}}$ (Определение 7).

2.5 Оценка сдвига испытуемого

Лемма 10 (МАР-оценка сдвига и усадка). В условиях Предположения 4 зафиксируем испытуемого s с моментами $t = 1, \dots, n_s$ и известными $\{c_t\}$; обозначим остатки $r_{s,t} := h_{s,t}^m - c_t$ и их среднее $\bar{r}_{s,\cdot} = \frac{1}{n_s} \sum_t r_{s,t}$. Тогда апостериорное распределение u_s^m гауссово, и его мода (совпадающая со средним) равна

$$\hat{u}_s^m = \arg \max_u p(u | \{r_{s,t}\}) = \frac{n_s}{n_s + \lambda} \bar{r}_{s,\cdot}, \quad \lambda = \frac{\sigma_\varepsilon^2}{\sigma_u^2}.$$

Доказательство. Остатки $r_{s,t} = u_s^m + \varepsilon_{s,t}^m$ суть n_s наблюдений u_s^m с независи-

мым изотропным шумом. Логарифм апостериорной плотности с точностью до постоянной:

$$\log p(u \mid \{r_{s,t}\}) = -\frac{1}{2\sigma_u^2}\|u\|^2 - \frac{1}{2\sigma_\varepsilon^2} \sum_t \|r_{s,t} - u\|^2 + \text{const.}$$

Приравнявая градиент нулю, $-\sigma_u^{-2}u + \sigma_\varepsilon^{-2} \sum_t (r_{s,t} - u) = 0$, откуда $(\sigma_u^{-2} + n_s \sigma_\varepsilon^{-2})u = \sigma_\varepsilon^{-2} \sum_t r_{s,t}$ и, домножая на σ_ε^2 , $\hat{u}_s^m = \sum_t r_{s,t} / (n_s + \lambda) = \frac{n_s}{n_s + \lambda} \bar{r}_{s,\cdot}$.

Гауссовость апостериорного распределения влечёт совпадение моды и среднего. □

Следствие 11 (Обучаемый сдвиг с регуляризацией реализует MAP). Пусть $\ell_t^q(\mathbf{b}) = \frac{1}{2\sigma_\varepsilon^2} \|(h_{s,t}^m - \mathbf{b}) - c_t\|^2$. Минимум по $\mathbf{b}$ целевой функции $J(\mathbf{b}) = \sum_t \ell_t^q(\mathbf{b}) + \frac{1}{2\sigma_u^2} \|\mathbf{b}\|^2$ достигается в точке $\hat{u}_s^m$ из Леммы 10; штраф $\frac{1}{2\sigma_u^2} \|\mathbf{b}\|^2$ соответствует априорному распределению $-\log p(u_s^m)$ с точностью до константы.

Доказательство. $J(\mathbf{b})$ совпадает с $-\log p(\mathbf{b} \mid \{r_{s,t}\})$ из доказательства Леммы 10 с точностью до аддитивной постоянной, поэтому его минимум есть та же MAP-точка $\hat{u}_s^m$. □

Замечание (Интуиция усадки и связь с контрастивным обучением). Математический смысл и физическая интерпретация полученной MAP-оценки сдвига $\hat{u}_s^m$ раскрываются через два ключевых аспекта:

- 1) **Эффект усадки (shrinkage):** Множитель $\frac{n_s}{n_s + \lambda} \in (0, 1)$ выступает в роли автоматического регулятора уверенности. Если по испытуемому s доступно мало моментов данных (n_s мало), то оценка сдвига принудительно стягивается к нулю. Это предотвращает переобучение на шуме. По мере роста объёма данных ($n_s \rightarrow \infty$) множитель стремится к единице, и

модель начинает полностью доверять эмпирическому среднему остатков

$$\bar{r}_{s,\cdot\cdot}$$

2) **Связь с функционалом InfoNCE:** В практической реализации мы заменяем честный квадратичный лосс из Леммы 10 на функцию потерь InfoNCE, штрафующую L2-регуляризатором $\frac{1}{2\sigma_u^2}\|\mathbf{b}_s\|^2$. Соответствие между теоретической MAP-оценкой и точкой минимума этого суммарного лосса распадается на две части:

- *Точная часть:* Квадратичный регуляризатор весов $\|\mathbf{b}_s\|^2$ строго эквивалентен взятию отрицательного логарифма гауссовского априорного распределения сдвига субъекта.
- *Приближённая часть:* В отличие от чистой гауссианы, лосс InfoNCE содержит знаменатель (негативные пары). Однако, если предположить, что негативные примеры распределены на сфере $\mathbb{S}^d$ изотропно (равномерно во все стороны), то математическое ожидание градиента знаменателя по вектору сдвига $\mathbf{b}_s$ зануляется, и оптимизация InfoNCE становится эквивалентна оптимизации компоненты правдоподобия (первого слагаемого целевой функции) MAP-оценки сдвигов.

3 МЕТОДЫ

3.1 Общая схема




Рисунок 3.1 — Архитектура кросс-модальной контрастивной модели.

Модель состоит из двух ветвей, обрабатывающих ЭЭГ и фМРТ независимо (рис. 3.1). Энкодеры $\mathcal{E}_e : \mathbb{R}^{C \times T_e} \rightarrow \mathbb{R}^{d_e}$ и $\mathcal{E}_f : \mathbb{R}^{X \times Y \times Z \times T_f} \rightarrow \mathbb{R}^{d_f}$ сопряжены с проекторами $\mathcal{P}_e : \mathbb{R}^{d_e} \rightarrow \mathbb{S}^d$, $\mathcal{P}_f : \mathbb{R}^{d_f} \rightarrow \mathbb{S}^d$; искомые отображения суть

$$\mathbf{f} = \mathcal{P}_e \circ \mathcal{E}_e, \quad \mathbf{g} = \mathcal{P}_f \circ \mathcal{E}_f.$$

Обучаемые субъектные смещения $\mathbf{b}_s^e, \mathbf{b}_s^f$ вычитаются из признаков каждого испытуемого до нормировки (§3.6). Модель обучается посредством двунаправленного multipositive InfoNCE

3.2 Энкодер ЭЭГ

$\mathcal{E}_e$ служит **LaBraM** [5] — трансформерная фундаментальная модель ЭЭГ, предобученная на крупном корпусе электроэнцефалографических данных методом маскированного авторекодирования. Модель принимает на вход тензор (B, C, T_e) , где C — число каналов (до 60 в зависимости от записи), $T_e = 3000$ — число временных отсчётов окна 15 с при частоте дискретизации 200 Гц, $d_e = 200$. Канальные позиционные эмбединги строятся по именам каналов из эталонного монтажа LaBraM из 128 электродов: пересечение активных каналов с монтажом вычисляется на уровне батча, что обеспечивает совместимость записей с разным набором электродов. Выход энкодера — вектор $[\text{CLS}] \in \mathbb{R}^{d_e}$. К весам применяются LoRA-адаптеры.

Проектор $\mathcal{P}_e$. Двухслойный MLP: $\mathbb{R}^{200} \xrightarrow{\text{Linear}} \mathbb{R}^{256} \xrightarrow{\text{BN, GELU, Dropout}} \xrightarrow{\text{Linear}} \mathbb{R}^{128} \xrightarrow{\text{LN, L2}} \mathbb{S}^d \subset \mathbb{R}^{128}$.

3.3 Энкодер фМРТ

$\mathcal{E}_f$ служит **NeuroSTORM** — объёмная авторекодирующая модель на основе трансформеров со сдвигающимися окнами (SWin-подобная архитектура), предобученная методом маскированного авторекодирования трёхмерных фМРТ-объёмов. Вход: $(B, 1, X, Y, Z, T_f)$, где $X = Y = Z = 96$ — пространственный размер тома в вокселях $2 \times 2 \times 2$ мм, $T_f \approx 7$ — число фреймов в окне 15 с при $\text{TR} = 2.1$ с, $d_f = 288$. Остов возвращает латентный тензор $(B, 288, 2, 2, 2, T_f)$; пространственное среднее по последнему фрейму даёт вектор $(B, 288) \in \mathbb{R}^{d_f}$,

передаваемый в проектор. LoRA-адаптеры применяются аналогично ЭЭГ части.

Проектор $\mathcal{P}_f$. Архитектура идентична $\mathcal{P}_e$, входная размерность заменена: $\mathbb{R}^{288} \rightarrow \mathbb{S}^d \subset \mathbb{R}^{128}$.




Рисунок 3.2 — Архитектуры используемых энкодеров: сверху — NeuroSTORM ($\mathcal{E}_f$), снизу — LaBraM ($\mathcal{E}_e$).

3.4 Предобработка ЭЭГ и фМРТ

ЭЭГ — Сигнал фильтруется в диапазоне $[0.5, 45]$ Гц и передискретизируется до 200 Гц.

Для каждого момента стимула t (TR-индекс) вырезается окно длиной 15 с, сдвинутое назад на величину HRF-задержки $\Delta = 4.2$ с: $t_{\text{EEG}} = t \cdot \text{TR} - \Delta - 15$ с.

Каждый канал нормируется по среднему и стандартному отклонению, вычис-

ленным по всей записи.

фМРТ Данные приводятся к пространству MNI152 и ресамплируются до разрешения $2 \times 2 \times 2$ мм; объём обрезаётся/дополняется до куба $96 \times 96 \times 96$ вокселей по методу NeuroSTORM. Для каждого момента t извлекается временной блок из T_f последовательных фреймов, захватывающий соответствующее окно.

3.5 Формирование батча

Алгоритм получения батча следующий:

- 1) Случайно семплируется одна активность.
- 2) Из неё жадно выбираются T моментов времени с минимальным интервалом margin для исключения скоррелированных кадров
- 3) Для каждого момента случайно выбирается K испытуемых, имеющих данные для данного момента

, где T - количество моментов из стимула в батче, K - количество испытуемых соответствующих одному моменту в батче




Рисунок 3.3 — Схема устройства батча, зеленые(положительные) блоки соответствуют одному моменту

3.6 Субъектные смещения




Рисунок 3.4 — Схема механизма субъектных смещений. Обучаемые векторы b_s^m поглощают индивидуальный сдвиг u_s^m , после чего проектор работает с представлением, центрированным вокруг стимульного латента c_t .

Согласно порождающей модели (§4), предпроекционный вектор каждого испытуемого содержит аддитивный субъектный сдвиг u_s^m , не связанный со стимулом. Без его устранения косинусное сходство пар одного испытуемого остаётся ненулевым вне зависимости от стимула, что препятствует работе контрастивного критерия.

Для аппроксимации u_s^m в каждую ветвь вводятся *обучаемые субъектные смещения* (рис. 3.4). Для каждой модальности $m \in \{e, f\}$ заводится таблица эмбедингов

$$B^m \in \mathbb{R}^{S \times d_m}, \quad b_s^m = B^m[s] \in \mathbb{R}^{d_m},$$

где $S = 22$ — число испытуемых, $d_e = 200$, $d_f = 288$ — размерности выходов LaBraM и NeuroSTORM соответственно. Вектор b_s^m вычитается из признаков

до нормировки:

$$\tilde{h}_{s,t}^m = h_{s,t}^m - \mathbf{b}_s^m,$$

после чего $\tilde{h}_{s,t}^m$ передаётся в проектор. Таблицы инициализируются нулями; весовая регуляризация (weight decay) штрафует $\|\mathbf{b}_s^m\|^2$, предотвращая переобучение на испытуемых с малым объёмом данных.

3.7 Анализ латентного пространства: ССА и ССМ

Для анализа структуры порождённого латентного пространства обученная модель применяется ко всем моментам одной записи в хронологическом порядке. Для фиксированного испытуемого s и записи из n моментов определим *фазовые траектории*:

$$\Gamma_s^e = (\tilde{\mathbf{f}}(\mathbf{E}_{s,1}), \tilde{\mathbf{f}}(\mathbf{E}_{s,2}), \dots, \tilde{\mathbf{f}}(\mathbf{E}_{s,n}))^\top \in \mathbb{R}^{n \times d}, \quad (3.1)$$

$$\Gamma_s^f = (\tilde{\mathbf{g}}(\mathbf{F}_{s,1}), \tilde{\mathbf{g}}(\mathbf{F}_{s,2}), \dots, \tilde{\mathbf{g}}(\mathbf{F}_{s,n}))^\top \in \mathbb{R}^{n \times d}, \quad (3.2)$$

где $d = 128$, а строки суть образы очищенных отображений $\tilde{\mathbf{f}} = \mathcal{P}_e \circ \mathcal{E}_e$ и $\tilde{\mathbf{g}} = \mathcal{P}_f \circ \mathcal{E}_f$ (Определение 7). Таким образом, Γ_s^e и Γ_s^f — кривые в $\mathbb{S}^d \subset \mathbb{R}^d$, параметризованные временем.

ССА. Канонический корреляционный анализ применяется к паре многомерных траекторий $\Gamma_s^e, \Gamma_s^f \in \mathbb{R}^{n \times d}$ одной записи. ССА находит линейные проекции $U \in \mathbb{R}^{d \times k}$, $V \in \mathbb{R}^{d \times k}$, максимизирующие суммарную корреляцию между $\Gamma_s^e U$ и $\Gamma_s^f V$, и тем самым оценивает степень линейного выравнивания траекторий в латентном пространстве.

ССМ. ССМ [19] применяется к первым РСА-компонентам фазовых траекторий Γ_s^e и Γ_s^f . Сходимость корреляции с ростом длины выборки свидетельствует о том, что обе траектории управляются общей динамической системой, то есть модель научилась отражать связанную нейронную динамику, а не только статичное попарное сходство.

3.8 Функция потерь

Multipositive функция потерь (supervised contrastive, [20]) вместе с регуляризатором, реализующим априорное распределение сдвига (Следствие 11), на обучающем мини-батче из B пар имеет вид

$$\begin{aligned} \mathcal{L} = & -\frac{1}{2B} \sum_{b=0}^{B-1} \left[\frac{1}{|P_b|} \sum_{j \in P_b} \log \frac{\exp(L_{bj})}{\sum_k \exp(L_{bk})} \right. \\ & \left. + \frac{1}{|P_b|} \sum_{i \in P_b} \log \frac{\exp(L_{ib}^\top)}{\sum_k \exp(L_{kb}^\top)} \right] \\ & + \frac{1}{2\sigma_u^2 |S_{\text{batch}}|} \sum_{s \in S_{\text{batch}}} (\|\mathbf{b}_s^e\|^2 + \|\mathbf{b}_s^f\|^2), \end{aligned}$$

где $L_{bj} = \langle \tilde{\mathbf{f}}(\mathbf{E}_b), \tilde{\mathbf{g}}(\mathbf{F}_j) \rangle / \tau$, а $\tilde{\mathbf{f}}, \tilde{\mathbf{g}}$ — очищенные представления Определения 7. Контрастивный член реализует оценку снизу условной взаимной информации представлений $I(\tilde{\mathbf{f}}(E); \tilde{\mathbf{g}}(F) \mid S) \leq I(E; F \mid S)$ [21; 22]; регуляризатор реализует априор МАР-оценки сдвигов $\{\mathbf{b}_s^m\}$ (Следствие 11), где S_{batch} — множество уникальных субъектов, представленных в текущем мини-батче. Симметричные слагаемые соответствуют направлениям сопоставления ЭЭГ $\rightarrow$ фМРТ и фМРТ $\rightarrow$ ЭЭГ.

4 ВЫЧИСЛИТЕЛЬНЫЙ ЭКСПЕРИМЕНТ

4.1 Метрики оценки

Для запроса i из выборки размера N обозначим через $\text{rank}(i)$ позицию истинно парного ответа в ранжированном по косинусному сходству списке. Качество выравнивания оценивается с помощью двух метрик:

$$\text{MRR} = \frac{1}{N} \sum_{i=1}^N \frac{1}{\text{rank}(i)}, \quad (4.1)$$

$$\text{R@}k = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[\text{rank}(i) \leq k]. \quad (4.2)$$

Метрики вычисляются в обоих направлениях поиска: $\text{ЭЭГ} \rightarrow \text{фМРТ}$ ($e \rightarrow f$) и $\text{фМРТ} \rightarrow \text{ЭЭГ}$ ($f \rightarrow e$).

4.2 Статистический анализ

Гипотезы и уровень значимости

Для всех процедур проверки уровень значимости фиксируется на уровне $\alpha = 0.05$. Проверяется следующая пара гипотез:

$$H_0: \mu_b^+ \leq \mu_b^-, \quad H_1: \mu_b^+ > \mu_b^-,$$

где μ_b^+ — среднее косинусное сходство истинно совпадающих (диагональных) пар в блоке данных b , а μ_b^- — среднее косинусное сходство несовпадающих пар в том же блоке.

Методология тестирования

Circular-shift permutation test Критерий направлен на проверку согласованности временных рядов с сохранением их внутренней автокорреляционной структуры. Для каждого блока b вычисляется наблюдаемая статистика $t_{\text{obs}} = \overline{\mu}^+ - \overline{\mu}^-$, усредненная по всем блокам.

Для построения эмпирического нулевого распределения последовательность ЭЭГ-эмбеддингов внутри каждого блока циклически сдвигается на случайную величину $\Delta t \in [\Delta_{\min}, n_b - 1]$, где $\Delta_{\min} = 10$ TR. Такой сдвиг разрушает истинное временное выравнивание между ЭЭГ и фМРТ, но сохраняет собственную динамику сигналов. Достижимый уровень значимости (ошибка I рода) рассчитывается как:

$$p = \frac{\#\{t_k^* \geq t_{\text{obs}}\} + 1}{K + 1},$$

где t_k^* — статистика, полученная на k -й итерации сдвига, $K = 5000$.

Sign test Менее чувствительный к форме распределения непараметрический критерий. Статистика критерий представляет собой число блоков (или субъектов), для которых выполнено условие $\mu_b^+ > \mu_b^-$. При справедливости H_0 данная величина распределена биномиально: $k \sim \text{Binomial}(n, 0.5)$. Критерий не требует предположения о симметрии распределения разностей.

Paired permutation test Использует информацию о величине эффекта без жестких параметрических предположений. Статистика критерия: $\bar{d} = \frac{1}{n} \sum_b (\mu_b^+ - \mu_b^-)$. Нулевое распределение формируется путем случайного изменения знаков

разностей $d_b = \mu_b^+ - \mu_b^-$ на противоположные ($K = 10\,000$ перестановок).

Коррекция псевдорепликации Поскольку один субъект может участвовать в нескольких сессиях (до 13 блоков), возникает внутрисубъектная зависимость данных. Для устранения эффекта псевдорепликации внутрисубъектные разности d_b усредняются до уровня субъекта. Это снижает объем выборки до $n = S = 22$ независимых наблюдений.

Устранение автокорреляции Близкие во времени окна ЭЭГ и фМРТ сильно коррелированы из-за специфики гемодинамического отклика и перекрытия самих окон. Чтобы исключить искусственное завышение сходства в альтернативных парах, из расчета μ_b^- исключаются все пары с временным расстоянием $|i - j| \leq 10$ TR. Блоки малой длительности, для которых такое исключение невозможно, отбрасываются (итоговое число блоков снижается до 98).

Результаты

Поскольку все процедуры представляют собой проверку устойчивости (robustness check) одной и той же базовой гипотезы, поправка на множественные сравнения не требуется. В качестве основного (наиболее консервативного) выбран sign и permutation критерии на уровне субъектов с lag'ом. Остальные конфигурации являются подтверждающими.

Результаты значимы ($p < 0.05$) во всех восьми конфигурациях, что указывает на высокую устойчивость обнаруженного эффекта выравнивания модальностей. Первичные критерии (выделены жирным) строго контролируют как псевдорепликацию, так и автокорреляционное смещение.

Таблица 4.1 — Результаты статистических критериев выравнивания ЭЭГ–фМРТ ($\alpha = 0.05$). Lag обозначает исключение пар со смещением $|i - j| \leq 10$ TR.

Тест	Уровень	Lag	n	p	Вывод
Circular-shift perm.	Блок	✓	253	< 0.001	H_0 отвергается
Sign	Блок	—	253	2.1×10^{-4}	H_0 отвергается
Sign	Субъект	—	22	6.1×10^{-5}	H_0 отвергается
Sign	Блок	✓	98	8.0×10^{-4}	H_0 отвергается
Sign	Субъект	✓	22	2.4×10^{-7}	H_0 отвергается
Парный перест.	Блок	—	253	$< 10^{-4}$	H_0 отвергается
Парный перест.	Субъект	—	22	$< 10^{-4}$	H_0 отвергается
Парный перест.	Блок	✓	98	$< 10^{-4}$	H_0 отвергается
Paired perm.	Субъект	✓	$z = 3.70$	$< 10^{-4}$	H_0 отвергается

4.2.1 ССА и ССМ

Для оценки линейной и нелинейной синхронизации скрытых пространств использовались методы ССА и ССМ.

ССА применялся к парам траекторий $\Gamma_s^e, \Gamma_s^f \in \mathbb{R}^{n_b \times 128}$ индивидуально для каждого блока. Во избежание вырождения матриц при малой длине временного ряда ($n_b \ll d$) размерность предварительно снижалась с помощью PCA до $n_{\text{pca}} = \min(10, \lfloor n_b/3 \rfloor)$ компонентов.

Первая каноническая корреляция составила:

$$\rho_1 = 0.37 \pm 0.03$$

Метод ССМ применялся к первым PCA-компонентам фазовых траекторий ($n_b \approx 170$ TR). Установившиеся значения корреляции составили:

$$\rho_{\text{EEG} \rightarrow \text{fMRI}}(L) = 0.31 \pm 0.04,$$

$$\rho_{\text{fMRI} \rightarrow \text{EEG}}(L) = 0.17 \pm 0.05.$$

Положительные значения корреляции сохраняются на всем диапазоне размеров библиотеки L , подтверждая наличие общей нелинейной динамической компоненты в обеих модальностях.

4.3 Метрики качества выравнивания

Таблица 4.2 — Качество кросс-модального поиска (среднее $\pm$ стандартное отклонение)

Метрика	Значение
$MRR_{e \rightarrow f}$	0.132 ± 0.012
$MRR_{f \rightarrow e}$	0.124 ± 0.016
$R@10_{e \rightarrow f}$	$28.8 \pm 2.8\%$

4.3.1 Данные

Эксперименты проводились на открытом датасете NatView [23] — одновременных записях ЭЭГ и фМРТ у здоровых взрослых испытуемых в условиях натуралистического просмотра видео.

Данные собраны у 22 испытуемых (возраст 23–51 лет) в двух сессиях. ЭЭГ записывалась системой Brain Products BrainCap MR с частотой 5 000 Гц; использовались 61 корковый электрод по системе 10–20, 2 канала ЭОГ и 1 канал ЭКГ. Функциональные изображения головного мозга получены на томографе Siemens TIM Trio 3 T ($TR = 2,1$ с, 38 аксиальных срезов, разрешение $3,47 \times 3,47 \times 3,33$ мм). Стимульный протокол включал состояние покоя, анимационный ролик Inscapes, короткометражный фильм *The Present*, два десятиминутных фрагмента *Despicable Me* (английская и венгерская дорожки) и три пятиминутных видеоролика с приматами (Monkey 1, 2, 5).

Разбиение на обучающую и тестовую выборки выполнено *по активностям*:

каждая уникальная активность целиком относится ровно к одному разделу. Такой способ разбиения гарантирует, что на этапе оценки модель никогда не встречала ни одного кадра текущего стимула во время обучения, — то есть тестовая выборка является held-out по содержанию стимула

4.4 Ограничения метода и практическая значимость

4.4.1 Ограничения текущего подхода

Отсутствие обобщения на новых субъектах. Механизм субъект-зависимых смещений требует включения целевого испытуемого в обучающую выборку. Для нового испытуемого $i^* \notin \{1, \dots, 22\}$ смещение $\mathbf{o}^{(i^*)}$ неизвестно. Few-shot дообучение смещения по нескольким записям потенциально решает проблему, но не было проверено экспериментально.

Полный объёмный фМРТ без парцелляции. Обработка 96^3 вокселей потребовала пошаговых контрольных точек для LaBraM и NeuroSTORM, увеличив время прохода на 30%. Применение атласной парцелляции (например, к 200 ROI по Schaefer) снизило бы вычислительную нагрузку на $100\times$ при возможной потере пространственной информации.

Фиксированный сдвиг HRF. Единый сдвиг $\Delta = 4,2$ с (2 TR) используется для всех испытуемых и всех областей мозга. Субъект-специфичная и регионально-специфичная HRF-коррекция может улучшить качество согласования пар.

4.4.2 Практическая значимость

Механизм субъект-зависимых смещений. Нулевая инициализация + вычитание смещения до проектора — архитектурно простое решение, не требующее изменений в энкодерах. Механизм переносим на любую задачу, где присутствует межсубъектная вариативность представлений: нейромониторинг, адаптивные ИНМ, долгосрочные нейровизуализационные исследования.

4.4.3 Направления дальнейших исследований

- 1) **EEG next-frame prediction** Реализация авторегрессионного детектора границ состояний мозга — предсказание следующего патча LaBraM из текущего скрытого состояния — что поможет ввести вариативный размер окна.
- 2) **Few-shot перенос** Дообучение $\mathbf{o}^{(i*)}$ для нового испытуемого по 5-10 записям при замороженных остальных параметрах. Это переход от чисто внутрисубъектного метода к практически применимому.
- 3) **Использование атласов мозга** Использование 200 ROI Schaefer вместо полного объёма снизит вычислительную нагрузку в $100\times$ и позволит проводить региональный анализ.
- 4) **Субъект-специфичная HRF** Оценка индивидуальной HRF по предварительным блочным сессиям и адаптация сдвига Δ для каждого испытуемого.
- 5) **Расширение на другие датасеты** Проверка переносимости метода на наборы данных с большим числом испытуемых (например, Human Connectome Project resting-state + EEG).

ЗАКЛЮЧЕНИЕ

В настоящей работе построена кросс-модальная контрастивная модель совместного представления ЭЭГ и фМРТ и исследована взаимосвязь порождённых фазовых траекторий на наборе данных NatView [9]. Все поставленные задачи решены в полном объёме.

Задача 1. Реализована двухмодальная архитектура на основе энкодеров LaBraM [5] и NeuroSTORM, адаптированных методом LoRA [6].

Задача 2. Предложен механизм субъект-зависимых смещений b_s^e, b_s^f , выводимых из порождающей модели как MAP-оценка индивидуального латентного смещения при гауссовском априорном распределении. Экспериментально подтверждено, что метод достигает $MRR_{e \rightarrow f} = 0,132 \pm 0,012$ и $R@10_{e \rightarrow f} = 28,8 \pm 2,8 \%$, что в $\approx 53 \times$ превышает случайный уровень по MRR.

Задача 3. Выявлены три основных ограничения метода: отсутствие обобщения на новых испытуемых без дообучения; зависимость от качества временного выравнивания ЭЭГ и фМРТ через HRF; вычислительная нагрузка полного объёма без парцелляции. Направления дальнейших исследований включают few-shot адаптацию на новых субъектах, использование атласов мозга для снижения размерности и количественный анализ фазовых траекторий методами ССМ.

Практическая значимость. Предложенная архитектура и механизм субъектных смещений переносимы на задачи мультисубъектного нейродекодирования. Анализ фазовых траекторий посредством ССА и ССМ открывает путь к интерпретируемой оценке качества выравнивания как меры связанности нейронной динамики двух модальностей.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Learning Transferable Visual Models From Natural Language Supervision / A. Radford [и др.] // ICML. — 2021. — arXiv: 2103.00020.
2. Reconstructing the Mind's Eye: fMRI-to-Image with Contrastive Learning and Diffusion Priors / P. S. Scotti [и др.] // NeurIPS. — 2023. — arXiv: 2305.18274.
3. NeuroBOLT: Resting-state EEG-to-fMRI Synthesis with Multi-dimensional Feature Mapping / Y. Li [и др.] // NeurIPS. — 2024. — arXiv: 2410.05341.
4. *Warbrick T.* Simultaneous EEG-fMRI: What Have We Learned and What Does the Future Hold? // Sensors. — 2022. — DOI: 10.3390/s22062262.
5. *Jiang W.-B., Zhao L.-M., Lu B.-L.* Large Brain Model for Learning Generic Representations with Tremendous EEG Data in BCI // ICLR. — 2024. — arXiv: 2405.18765.
6. LoRA: Low-Rank Adaptation of Large Language Models / E. J. Hu [и др.] // ICLR. — 2021. — arXiv: 2106.09685.
7. *Oord A. van den, Li Y., Vinyals O.* Representation Learning with Contrastive Predictive Coding // arXiv. — 2018. — arXiv: 1807.03748.
8. Fine-Tuning can Distort Pretrained Features and Underperform Out-of-Distribution / A. Kumar [и др.] // ICLR. — 2022. — arXiv: 2202.10054.
9. *Telesford Q. K., Gonzalez-Moreira E., Biswal B. B.* An open-access dataset of naturalistic viewing using simultaneous EEG-fMRI // Scientific Data. — 2023. — DOI: 10.1038/s41597-023-02458-8.
10. Nonlinear Event-Related Responses in fMRI / K. J. Friston [и др.] // Magnetic Resonance in Medicine. — 1998. — Т. 39, № 1. — С. 41—52. — DOI: 10.1002/mrm.1910390109.
11. *Handwerker D. A., Ollinger J. M., D'Esposito M.* Variation of BOLD hemodynamic responses across subjects and brain regions and their effects on statistical analyses // NeuroImage. — 2004. — Т. 21, № 4. — С. 1639—1651. — DOI: 10.1016/j.neuroimage.2003.11.029.
12. *Nastase S. A., Goldstein A., Hasson U.* Measuring shared responses across subjects using intersubject correlation // Social Cognitive and Affective Neuroscience. — 2019. — DOI: 10.1093/scan/nsz037.

13. *Wang T., Isola P.* Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere // ICML. — 2020. — arXiv: 2005.10242.
14. Understanding Dimensional Collapse in Contrastive Self-supervised Learning / T. Hua [и др.] // ICLR. — 2021. — arXiv: 2110.09348.
15. *Bardes A., Ponce J., LeCun Y.* VICReg: Variance-Invariance-Covariance Regularization for Self-Supervised Learning // ICLR. — 2022. — arXiv: 2105.04906.
16. EEGNet: a compact convolutional neural network for EEG-based brain-computer interfaces / V. J. Lawhern [и др.] // Journal of Neural Engineering. — 2018. — DOI: 10.1088/1741-2552/aace8c.
17. *Gu A., Dao T.* Mamba: Linear-Time Sequence Modeling with Selective State Spaces // ICLR. — 2023. — arXiv: 2312.00752.
18. A Reduced-Dimension fMRI Shared Response Model / P.-H. Chen [и др.] // NeurIPS. — 2015.
19. Detecting Causality in Complex Ecosystems / G. Sugihara [и др.] // Science. — 2012. — Т. 338, № 6106. — С. 496—500. — DOI: 10.1126/science.1227079.
20. Supervised Contrastive Learning / P. Khosla [и др.] // NeurIPS. — 2020. — arXiv: 2004.11362.
21. *Oord A. van den, Li Y., Vinyals O.* Representation Learning with Contrastive Predictive Coding // arXiv. — 2018. — arXiv: 1807.03748.
22. On Variational Bounds of Mutual Information / B. Poole [и др.] // ICML. — 2019. — arXiv: 1905.06922.
23. *Telesford Q. K., Gonzalez-Moreira E., Biswal B. B.* An open-access dataset of naturalistic viewing using simultaneous EEG-fMRI // Scientific Data. — 2023. — DOI: 10.1038/s41597-023-02458-8.